

Trabalho Prático: Algoritmos de Clustering

Qualquer dúvida, mandar para: ecradaelli@inf.ufsm.br

Cada dupla deverá escolher um dataset real da área da saúde e realizar o pré-processamento necessário antes da aplicação dos algoritmos de clustering, utilizando algum método de análise descritiva.

OBS: Não usar o rótulo na clusterização (remover a coluna de classe/outcome antes de rodar os algoritmos). Porém, após a clusterização, os rótulos originais podem ser readicionados para **avaliação e interpretação** dos clusters encontrados.

Requisitos do Dataset

O dataset deve:

- Ser real (não sintético)
- Possuir mais de 1000 instâncias
- Ser relacionado a:
 - Diabetes
 - Doença cardiovascular
 - Hipertensão
 - *OBS: No máximo duas duplas com o mesmo tipo de dataset*
- Ter sido utilizado em artigo científico (journal paper)
- O artigo utilizado deve ser citado no relatório

Sugestões de sites para encontrar o dataset:

- [UCI Machine Learning Repository](#)
- [Kaggle Datasets](#)
- [PhysioNet](#)
- [Bioinformatics Data](#)

Definição do Problema

Antes de rodar os algoritmos, os alunos devem **definir claramente um problema que querem resolver** com o clustering.

Exemplos de problemas bem definidos:

- **Diabetes:**
 - Ver se pacientes jovens formam um grupo e idosos outro
- **Hipertensão:**

- Descobrir se existe grupo de pressão muito alta versus pressão moderada
- **Doença Cardiovascular:**
 - Ver se grupos correspondem a risco baixo, médio e alto

Análise Descritiva

- **Univariada:** entender cada variável sozinha e detectar outliers
 - *Métodos:* Média, Mediana, Desvio padrão, Mínimo, Máximo, Quartis, Histograma, Boxplot
- **Bivariada:** medir relação entre pares de variáveis e identificar redundâncias
 - *Métodos:* Correlação de Pearson, Correlação de Spearman, Gráfico de dispersão
- **Multivariada:** visualizar relações gerais e reduzir dimensionalidade
 - *Métodos:* Matriz de correlação (heatmap), PCA (Análise de Componentes Principais)

Pré-processamento

- Tratar valores faltantes: algoritmos não aceitam NaN
- Tratar outliers: evitam distorção dos clusters
- Padronizar/normalizar: evita que variáveis com valores grandes dominem as pequenas
- Remover colunas desnecessárias: ID, nome e data só adicionam ruído
- Remover o rótulo: clustering é não supervisionado (não pode usar a resposta)
- Reduzir com PCA (opcional): diminui variáveis, custo e facilita visualização
- Verificar NaN e dados numéricos: garante que tudo está pronto para os algoritmos

Algoritmos

Implementar utilizando Scikit-learn: Cada algoritmo com diferentes hiperparâmetros testados.

- **K-Means**
- **Agglomerative Clustering (com diferentes métodos de linkage)**
- **DBSCAN**

Métricas de Avaliação

Comparar internamente quais hiperparâmetros tiveram melhores resultados e depois comparar os algoritmos entre si, utilizando:

- Silhouette Score
- Davies-Bouldin Index
- Calinski-Harabasz Score

O Relatório Deve Conter

- Descrição do dataset (análise descritiva)
- Pré-processamento realizado

- Tabelas e gráficos dos resultados
- Comparação e discussão das similaridades e diferenças entre os resultados obtidos

Entrega

Enviar até 03/06 para: ecradaelli@inf.ufsm.br

A pasta .zip deve conter:

- Código Python (.py)
- Dataset (.csv)
- Relatório (.pdf)

Nome da pasta: Nome(s)_trabalho_clustering.zip

Caso seja em dupla, ambos devem enviar a pasta.